

Delta H — Resumo Acessível

Para que serve este documento?

Este documento explica, em linguagem simples, o que é o projeto **Delta H**, o que estamos calculando, por que isso importa e como será feita a coleta de dados com leitores. Não é necessário conhecimento prévio de matemática ou programação.

1. A ideia central (em uma frase)

Queremos medir o quanto um texto é "difícil de entender" analisando a estrutura do texto — não apenas o vocabulário — e verificar se essa medida prevê o desempenho de leitores reais.

2. O problema que motiva o trabalho

2.1 Como se mede a dificuldade de um texto hoje?

Os métodos tradicionais (Flesch-Kincaid, por exemplo) contam:

- Número de palavras por frase
- Número de sílabas por palavra
- Frequência de palavras no vocabulário

Problema: Esses métodos ignoram a **estrutura do texto** — como as ideias se conectam, como o texto se organiza em cenas, como a narrativa se desenvolve.

2.2 O que queremos medir?

Queremos medir algo diferente: **a distância entre a estrutura global do texto e a estrutura que o leitor consegue ver em um trecho específico.**

Exemplo intuitivo:

- Imagine um romance com 10 capítulos. Cada capítulo tem uma "cena" com personagens, diálogos e descrições.
- Se você lê ****apenas um parágrafo****, vê uma pequena parte da história — um fragmento.
- Se você lê ****um capítulo inteiro****, vê uma sequência completa de cenas — uma estrutura mais rica.
- Se você lê ****o livro inteiro****, vê todas as conexões entre personagens, temas e eventos — a estrutura completa.

A **hipótese**: Quanto maior a diferença entre o que o leitor vê (trecho) e a estrutura completa do texto, mais difícil é para o leitor entender a história.

3. O que estamos calculando?

3.1 A metáfora do "mapa"

Pense no texto como um **mapa de uma cidade**:

Conceito	Metáfora	No texto
Estrutura global	O mapa completo da cidade	Todas as frases do texto, com suas conexões
Estrutura local	O que você vê da janela de um prédio	Um trecho específico que o leitor está lendo
Gap (Δ)	A diferença entre o mapa e a vista da janela	A diferença entre a estrutura completa e o trecho

3.2 Como calculamos isso?

Usamos uma técnica matemática chamada **Análise Topológica de Dados (TDA)**. Em termos simples:

1. **Transformamos cada frase em um ponto** no espaço (usando inteligência artificial para entender o significado das frases)
2. **Conectamos os pontos** que são parecidos (frases com significado semelhante ficam próximas)
3. **Analisamos a forma** dessa rede de conexões:
 - Quantos "aglomerados" de frases existem?
 - Quantos "ciclos" (ideias que se conectam de formas diferentes) existem?
 - Como essas estruturas variam em diferentes escalas?
4. **Comparamos** a estrutura do trecho (o que o leitor vê) com a estrutura de um pedaço aleatório do mesmo tamanho (para controlar o efeito do tamanho do trecho)

3.3 O resultado: Delta H (ΔH)

O **Delta H** é um número que mede **quanto a estrutura do trecho difere da estrutura esperada** de um pedaço aleatório do mesmo texto.

- **ΔH alto** = o trecho tem uma estrutura muito diferente do esperado (mais "conectado" ou mais "fragmentado")
- **ΔH baixo** = o trecho tem uma estrutura parecida com a de um pedaço aleatório

3.4 O que o Delta H **não** é

- **Não é** uma medida de dificuldade léxica (palavras difíceis)

- **Não é** uma medida de tamanho do texto
 - **Não é** uma medida de qualidade literária
-

4. Por que isso importa? (Pertinência)

4.1 Para a educação

- **Avaliação de textos:** Podemos identificar trechos que são "difíceis" não por causa do vocabulário, mas por causa da estrutura narrativa
- **Adaptação de materiais:** Podemos sugerir adaptações de textos para diferentes níveis de leitores
- **Ensino de leitura:** Podemos ensinar leitores a identificar estruturas narrativas complexas

4.2 Para a ciência

- **Nova métrica:** O Delta H é uma medida objetiva e matemática de "complexidade estrutural" de um texto
- **Compreensão de leitura:** Podemos testar se a estrutura do texto prevê a compreensão melhor que medidas tradicionais
- **Interdisciplinaridade:** O projeto conecta matemática, ciência da computação e linguística

4.3 Para a sociedade

- **Acessibilidade:** Textos complexos podem ser identificados e adaptados para pessoas com dificuldades de leitura
 - **Tradução:** A estrutura topológica pode ajudar a avaliar se uma tradução preserva a estrutura narrativa original
 - **Preservação cultural:** Podemos analisar como a estrutura narrativa varia entre culturas e épocas
-

5. O que é original neste trabalho? (Originalidade)

5.1 Primeira aplicação de TDA à compreensão de leitura

Até onde sabemos, este é o **primeiro estudo** a usar Análise Topológica de Dados para prever compreensão de leitura.

5.2 Nova métrica: entropia persistente

A definição de Delta H como **entropia sobre comprimentos de barra** (em vez de perfil de Betti) é uma contribuição original ao campo de TDA.

5.3 Descoberta da inversão de sinal

Descobrimos que o sinal do gap **inverte** entre escalas:

- **Janela curta (250 palavras):** O trecho tem **menos** estrutura que um pedaço aleatório (ΔH negativo)

- **Trecho longo (4000 palavras):** O trecho tem **mais** estrutura que um pedaço aleatório (ΔH positivo)

Essa inversão é mecanicamente explicada e foi uma descoberta nova.

5.4 Desenho experimental rigoroso

O projeto usa:

- **Referência casada por tamanho:** Comparação com pedaços aleatórios do mesmo tamanho (não com a obra inteira)
 - **Teste união-interseção:** Só declaramos suporte se duas métricas independentes concordarem
 - **Pré-registro:** Todas as decisões são congeladas antes de ver dados de leitores
-

6. O que já foi feito?

6.1 Fase 1 — Pipeline e corpus

- 9 obras do Project Gutenberg baixadas e verificadas
- Pipeline completo funcionando (frases $\rightarrow$ embeddings $\rightarrow$ topologia $\rightarrow$ métricas)
- Figuras geradas

6.2 Fase 2 — Piloto computacional (quase concluída)

- 7 rodadas computacionais executadas (7.446 janelas + 150 segmentos)
- 9 decisões congeladas (forma da métrica, escala, controles, etc.)
- Controles C1–C5 executados e verificados
- Análises de sensibilidade completadas

6.3 Resultados preliminares

- **Sinal negativo em 9/9 obras** na escala de janela ($p \leq 1,4 \times 10^{-22}$)
 - **Sinal positivo em 72,7% dos segmentos** na escala de trecho ($p = 1,3 \times 10^{-8}$)
 - **Controles robustos:** C1 (4,63×), C2 (25,59×)
 - **Concordância entre métricas:** $\rho = -0,724$
-

7. O que falta fazer?

7.1 Fase 2 — Robustez de embedding (pendente)

- Testar o pipeline com outros modelos de embedding (LaBSE, fastText)
- Verificar se o sinal do gap é consistente entre modelos

7.2 Fase 3 — Pré-registro

- Escrever o documento de pré-registro (NT-03)

- Congelar todas as decisões estatísticas

7.3 Fase 4 — Piloto de calibração

- Testar o questionário com 5–10 leitores
- Ajustar o procedimento de coleta

7.4 Fase 5 — Coleta completa

- 54 leitores $\times$ 2 trechos = 108 observações
- Cada trecho lido exatamente 3 vezes

7.5 Fase 6 — Artigo

- Análise multinível
- Escrita do artigo científico

8. Guia de Coleta de Dados com Leitores

8.1 Visão geral

Elemento	Especificação
Participantes	54 leitores
Trechos	36 trechos (18 alto- Δ + 18 baixo- Δ)
Obras	6 obras (2 simples, 2 intermediárias, 2 complexas)
Observações	108 (54 leitores $\times$ 2 trechos)
Por trecho	3 leitores diferentes
Duração	~30–40 min por leitor

8.2 Critérios de inclusão para leitores

Inclusão:

- Idade $\geq$ 18 anos
- Ensino médio completo ou superior
- Leitor habitual (lê pelo menos 1 livro por mês)
- Português ou inglês nativo ou fluente

Exclusão:

- Dificuldade visual não corrigida
- Distúrbio de leitura diagnosticado (dislexia, etc.)
- Participação em estudos similares nos últimos 6 meses

8.3 Os 36 trechos

Os trechos foram selecionados automaticamente com base no valor de Delta H:

Tipo	Quantidade	Descrição
**Alto- Δ **	18 trechos	Trechos com estrutura muito diferente do esperado
**Baixo- Δ **	18 trechos	Trechos com estrutura parecida com a de um pedaço aleatório

Distribuição por obra:

Nível	Obras	Trechos
Simples	Alice's Adventures in Wonderland, The Metamorphosis	6 + 4 = 10
Intermediário	Dom Casmurro, Memórias Póstumas de Brás Cubas	6 + 6 = 12
Complexo	Ulysses, Quincas Borba	8 + 6 = 14

8.4 Atribuição de trechos a leitores

Cada leitor recebe **2 trechos** de níveis diferentes:

Par	Quantidade	Descrição
-----	------------	-----------

SI (Simples + Intermediário)	12 leitores	1 trecho simples + 1 trecho intermediário
SC (Simples + Complexo)	18 leitores	1 trecho simples + 1 trecho complexo
IC (Intermediário + Complexo)	24 leitores	1 trecho intermediário + 1 trecho complexo
Total	**54 leitores**	**108 observações**

8.5 Procedimento de coleta

Passo 1 — Preparação

1. Verificar se o leitor atende aos critérios de inclusão

2. Obter consentimento informado (assinado)

3. Coletar dados demográficos:

- Idade
- Escolaridade (anos de estudo)
- Familiaridade com literatura (auto-relato + teste objetivo)

Passo 2 — Leitura

1. Apresentar o primeiro trecho (4000 palavras, ~20–30 min de leitura)
2. O leitor lê o trecho em silêncio
3. O leitor pode fazer anotações, mas não pode voltar ao texto durante o questionário

Passo 3 — Questionário

Após a leitura, o leitor responde:

5 itens locais (sobre o trecho lido):

1. Quem falou neste trecho?
2. Onde ocorreu a cena principal?
3. Qual foi o evento principal?
4. Quem eram os personagens presentes?
5. O que aconteceu antes/depois deste trecho?

5 itens globais (sobre a estrutura do trecho):

1. Qual é o tema central deste trecho?
2. Como os eventos se conectam?
3. Qual é o conflito principal?
4. Como os personagens se relacionam?
5. Qual é a mensagem ou ideia principal?

Escala: 4 alternativas (múltipla escolha), com piso corrigido por sorte (0,25)

Passo 4 — Segunda leitura

1. Apresentar o segundo trecho (mesmo procedimento)
2. Aplicar o questionário novamente

Passo 5 — Encerramento

1. Agradecer ao leitor
2. Registrar dados da sessão
3. Anonimizar dados (conforme LGPD)

8.6 Cálculo do escore (S)

O escore de compreensão é calculado como:

$$S = 0,3 \times S_{\text{local}} + 0,7 \times S_{\text{global}}$$

Onde:

- **S_{local}** = média dos 5 itens locais (corrigida por sorte)
- **S_{global}** = média dos 5 itens globais (corrigida por sorte)

Correção por sorte:

$$S_{\text{corrigido}} = (\text{acertos} - 0,25) / 0,75$$

Isso corrige o fato de que, com 4 alternativas, um leitor que chuta aleatoriamente acerta 25% das questões.

8.7 Análise estatística

Modelo principal:

$$S_{ij} = a_{obra(j)} - b \times \Delta_{gap}(j) + c1 \times \text{Escolaridade} + c2 \times \text{Idade} + c3 \times \text{Familiarid}$$

Onde:

- S_{ij} = escore do leitor i no trecho j
- $a_{obra(j)}$ = efeito fixo por obra (intercepto diferente para cada obra)
- $\Delta_{gap} = \ln(1 + |z_H|)$ — o preditor principal
- b = coeficiente que testamos ($H_0: b = 0$ vs $H_1: b > 0$)

Teste união-interseção:

- Só declaramos suporte à teoria se **ambas** as métricas (ΔH e d_B) rejeitarem H_0 a $\alpha = 0,05$

8.8 Considerações éticas

- **Consentimento informado:** Todos os leitores assinam um termo de consentimento

- **Anonimização:** Dados são anonimizados conforme LGPD
 - **Voluntariedade:** O leitor pode desistir a qualquer momento
 - **Compensação:** A definir (se aplicável)
 - **Aprovação ética:** O projeto deve ser aprovado por um Comitê de Ética em Pesquisa (CEP)
-

9. Perguntas frequentes

P: O que é "entropia persistente"?

R: É uma medida matemática que quantifica a "heterogeneidade" das estruturas em um diagrama de persistência. Em termos simples, mede quantas "escalas" diferentes de estrutura existem no texto.

P: Por que 4000 palavras?

R: Porque é o tamanho mínimo para que a estrutura topológica seja estável. Trechos mais curtos têm estruturas muito instáveis (muito sensíveis a pequenas mudanças).

P: Por que 54 leitores?

R: Porque o cálculo de poder amostral indicou que 108 observações (54 leitores $\times$ 2 trechos) são suficientes para detectar um efeito moderado ($|r| \approx 0,45$) com 80% de poder.


P: O que acontece se a hipótese não for confirmada?

R: Isso é um resultado legítimo e será publicado. A ciência avança também com resultados negativos.

P: Posso usar o Delta H para avaliar meus próprios textos?

R: Ainda não. O Delta H está em fase de validação. Após a confirmação, ele pode se tornar uma ferramenta útil para educadores e editores.

10. Resumo visual



5. Coleta com leitores:

- 54 leitores × 2 trechos = 108 observações

- Questionário: 5 itens locais + 5 itens globais

- Escore $S = 0,3 \times S_{\text{local}} + 0,7 \times S_{\text{global}}$

6. Análise:

$S = a - b \times \Delta H + \text{covariáveis}$

$H_0: b = 0 \quad \text{vs} \quad H_1: b > 0$

11. Contato e referências

Projeto: Delta H — Validação Empírica do Gap Topológico Narrativo

Documentos técnicos:

- NT-01: Estado do Projeto e Escolha da Métrica Primária
- NT-02: Relatório do Piloto Computacional e Congelamento da Forma da Métrica

Referências principais:

- Chazal, Cohen-Steiner, Mérigot — *Persistence-based clustering / stability of Rips*
- Edelsbrunner, Harer — *Computational Topology: An Introduction*
- Munch, Wang — *Applied Topological Data Analysis*

- Green, S. B. (1991) — *How many subjects does it take to do a regression analysis?*
 - Gelman & Hill — *Data Analysis Using Regression and Multilevel/Hierarchical Models*
-

Documento gerado em 28/09/2026. Projeto em Fase 2 (piloto computacional).